

一节课搞懂大模型应用开发

课程内容

1. 大模型对哪些行业产生了影响
2. 想要胜任这个岗位你需要会哪些AI技术？
3. 需要会哪些应用技术
4. 岗位就业必须要懂的算法原理

知乎知学堂

知乎知学堂是**知乎旗下**的职业教育品牌，于2022年12月30日正式发布。知乎知学堂依托自身科技实力，专注于用户职业发展，聚集各行业优质教育资源，打造了一站式在线职业教育平台。

2023年至今，累计为超过50万泛IT从业人员提供职业培训服务。

累计为超100+家头部企业提供AI培训及咨询服务，涵盖互联网、制造业、金融、快消等各行业

完课福利

1. AI + 行业场景全景图谱
2. 2025年中国企业级AI应用行业研究报告
3. 中国物流与供应链领域AI应用研究报告
4. “人工智能+”教育行业应用白皮书
5. 2025金融业大模型应用报告：体系落地 价值共生
6. 2025年中国人力资源数字化发展研究报告
7. AI Coding：超越软件的编程范式革命
8. AI应用开发知识图谱

2.2.2 大模型能力建设方式	20
2.2.3 大模型体系构建路径	21
2.3 场景落地：从效率工具向决策引擎演进	24
2.3.1 金融业大模型的应用版图	24
2.3.2 金融业大模型的演进路径	26
2.3.3 金融业大模型的应用新形态：智能体	28

第三章 金融业大模型建设的核心挑战与应对策略 31

3.1 金融 亿欧智库：人力资源行业传统AI技术发展

3.2 大模型 ◆ 视觉识别技术：招聘场景成熟度领先，行为分析潜力待释放

3.2.1 招聘面试评估场景

技术成熟度：技术成熟，已形成全链路解决方案，但需注意算法偏见和数据隐私问题。

应用成熟度：结合语音语义分析与微表情识别，如AI面试官通过动态捕捉候选人微表情、语气等多模态数据，评估胜任力和人格特质。

3.3 金融 ◆ 语音识别技术：普通话场景成熟，方言支持持续突破

3.3.1 面试录音处理场景

技术成熟度：技术成熟，已形成全链路解决方案，但需注意算法偏见和数据隐私问题。
应用成熟度：结合语音语义分析与微表情识别，如AI面试官通过动态捕捉候选人微表情、语气等多模态数据，评估胜任力和人格特质。

3.3.5 ◆ OCR识别技术：为了准确了解AI工具在消费者群体中的实际应用情况，知名风险投资机构Menlo Ventures与专业市场调研公司Morning Consult于2025年4月联合开展了一项大规模调研。该调研针对5031名美国成年人，深入探讨了消费者在过去六个月中如何使用AI和其他工具完成特定活动，以及他们对这些技术的态度和接受度。

3.3.6 简历解析场景

技术成熟度：技术成熟，已形成全链路解决方案，但需注意算法偏见和数据隐私问题。

应用成熟度：对PDF复杂字体，如行书、

第四章

◆ RPA机器人流程自

员工入职场景

技术成熟度：技术成熟，已形成全链路解决方案，但需注意算法偏见和数据隐私问题。

应用成熟度：通过

等基本文件，从而

在消费者端，AI 渗透率最高的活动中，编程位居第二，渗透率达到47%，也就是接近一半的受访者已经在日常生活或工作中的编程都已经开始采用AI，广泛接受度仅次于写作支持。47%的渗透率表明AI编程工具跨越了早期采用者的边界，进入主流市场接受阶段，反映的是产品易用性和实用价值的显著提升。市场规模的爆发增长。

2025 金融业大模型应用报告：体系落地 价值共生.pdf	2.7 MB
“人工智能+”教育行业应用白皮书.pdf	6.7 MB
2025 年中国人力资源数字化发展研究报告.pdf	13.5 MB
中国物流与供应链领域 AI 应用研究报告.pdf	25 MB
AI Coding：超越软件的编程范式革命.pdf	23.2 MB
AI + 行业场景全景图谱.pdf	2.7 MB
2025 年中国企业级 AI 应用行业研究报告.pdf	2.8 MB

根据The Business Research Company的数据，全球AI编程工具市场规模预计将从2024年的62.1亿美元增长到2029年的181.6亿美元，期间的复合年增长率（CAGR）为23.9%。


其他的预测包括：Grand View Research则预测2023年的48.6亿美元将在2030年达到260.3亿美元，CAGR高达27.1%。而S&P Global则预计代码生成领域在2024-2029年间的复合年增长率（CAGR）将达到53%，超过其他人工智能生成模式。都指向行业处于快速规模扩张和利润增长的区间。

Eva

- 知乎教育  知乎知学堂 AI化项目负责人;
— 未来职业之路 —
- 知乎AI大模型研发项目组核心成员;
- 前海外保险管理APP创始人之一
- 前澳洲海外品牌管理公司PM;
- 悉尼科技大学IT硕士



一、大模型对哪些行业产生了影响？





失

19:23

5G

阿福



智能体



嗨~

让每个瞬间值得珍藏

点我试试

我的健康

健康数据



全民行动，科学减重1亿斤
1分钱领智能体脂秤

去看看

#

长期素颜对皮肤有好处吗?

#

早餐吃燕麦片能帮助控制体重吗?

AI 诊室

报告解读

拍皮肤

就医服务



发消息或按住说话...



19:23

5G

阿福



智能体



19:23

你已进入AI诊室

蚂蚁阿福



AI 诊室

问诊中

退出

01·选咨询人

02·描述症状

03·诊疗建议

你好~我是你的AI医生，我将通过深度问诊了解你的健康状况，并提供明确的诊疗建议。

你本次要为谁咨询呢?

结合个人信息，回答更具针对性哦

为本人咨询

新增咨询人

跳过，直接咨询



发消息或按住说话...



19:24

5G



智能体

搜索服务

百大名医

就医医保

减重专区

健康生活

全部

院士领衔

国医大师

乳腺专科



王俊院士团队

中国工程院 院士团队 胸外科

三甲 北京大学人民医院

擅长：胸部疾病微创诊疗、肺癌精准治疗、智能外科技术研发及临床转化多个前沿方向

134.0 万人咨询

王俊医生AI分身是什么?

去问问



王宁利@FUXI

中国工程院 院士团队 眼科 博士生导师

三甲 首都医科大学附属北京同仁医院

擅长：各类青光眼、白内障、高度近视眼内镜屈光手术、遗传性眼病手术及激光治疗。

6.8 万人咨询



柴嵩岩国医大师

中医妇科

三甲 首都医科大学附属北京中医医院

擅长：各种类型的闭经、不孕症、妊娠病、产后病、妇科肿瘤、妇科炎症等。

4.7 万人咨询



董家鸿院士团队

中国工程院 院士团队 肝胆胰外科

大模型对哪些行业产生了影响？

互联网、地产、制造、医疗、零售、金融、物流、文旅、采矿、教育、农业、城市

地产开发

智能投资拿地决策
智能设计与方案优化
图纸智能审核与合规校验

地产建造

智慧工地全流程监管
施工安全智能预警与处置
施工进度与质量动态管控
智能供应链协同管理

地产营销

智能获客与用户画像精准勾勒
沉浸式智能营销展示
营销内容智能生成与运营
客户线索智能跟进与转化

地产运营

智慧物业服务
资产盘活与管理
智慧社区生活服务
能耗与环境智能管控

工厂建设

工厂数字化规划设计
数字基础设施建设
数字孪生工厂构建

研发设计

产品数字化设计
产品虚拟验证
工艺数字化设计
制造工程优化

生产制造

生产计划优化
车间智能排产
生产进度跟踪
生产动态调度
仓储智能管理
物料精准配送

危险作业自动化
安全一体化管控
能源智能管控
碳资产全生命周期管理
污染在线管控
网络协同制造

柔性产线快速换产
工艺动态优化
先进过程控制
人机协同作业
在线智能检测
质量精准追溯

质量分析与改进
设备运行监控
设备故障诊断与预测
设备维修维护

运营管理

智能经营决策
数智精益管理
规模化定制
产品精准营销

产品服务

远程运维服务
产品增值服务
客户主动服务

供应链管理

供应商数字化管理
采购计划优化协同
供应链风险预警与调度
供应链物流智能配送

能源生产智能化

传统能源智能生产

- 火力发电
- 水力发电
- 核电

可再生能源智慧管理

- 光伏电站
- 风力发电
- 其他可再生能源(生物质能、海洋能)

能源传输智能化

智能输电网络

- 输电线路监测
- 智能变电站

智能配电网网络

- 智能配电网规划运行
- 智能配电自动化

能源存储智能化

电化学储能智能管理
其他储能技术智能应用(压缩空气、飞轮储能、氢能储能)

能源消费智能化

工业能源智能管理
建筑能源智能管理
交通能源智能管理

能源调度与交易智能化

智能电网调度
能源大数据分析平台
能源市场交易智能化
需求响应与虚拟电厂

智慧医疗服务管理

医疗服务
医药服务
医保服务
医院管理

智慧基层公共卫生服务

健康管理服务
公共卫生服务
养老托育服务

智慧健康产业

医用机器人
药物研发

智慧教学科研

医学教学
医学科研

智慧医疗服务管理

医疗服务
医药服务
医保服务

智慧基层公共卫生服务

健康管理服务
公共卫生服务
养老托养服务

智慧健康产业

医用机器人
药物研发

智慧教学科研

医学教学
医学科研

大模型对哪些行业产生了影响?

产品设计

智能设计/产品辅助设计

生产制造

数字孪生/仿真优化生产流程

供应链管理

仓储与商品库存管理

市场营销

AI辅助营销/广告

用户运营

智能客服/AI外呼

互联网、地产、制造、医疗、零售、金融、物流、文旅、采矿、教育、农业、城市

质量检测

无人零售/智能门店等(包含智能商品识别等)

数字人直播

前中台应用场景

智能运营与管理
智能获客与营销
智能客户服务
智能产品与服务创新

监管科技

智能信息披露
智能交易监控
监管报告生成
用户身份识别

细分行业应用

零售金融
公司金融
保险
证券及资管

风险管理

智能风控体系
智能合规与内控
风险评估

后台应用

运维管理
告警管理

智慧园区

巡更巡检
园区安防
资产管理
能耗管理

智能闸口
安全告警
自定义办公文件模板识别

数字员工-报关助理
应用市场
堆场作业智能预采集

智慧仓储

库存优化
仓储布局优化
库内安全监测
自动化无人化搬运

运输配送

运输优化
智能履约
安全管理
货物安全监控

智能装载
智能调度
车队管理

自动驾驶
无人配送

智能导览与讲解

多模态导览
个性化讲解
数字人导览

内容创作与营销创新

智能内容生成
营销创新
数字文创

沉浸式体验构建

XR 沉浸体验
数字孪生
多感官体验

服务升级与个性化

智能客服
AI 行程规划
智能住宿推荐
情感化服务

运营管理优化

客流管理
收益管理
智能安防

文化遗产保护与传承

智能文物修复
数字化保护
非遗活化

资源勘探

地质建模
矿化预测
遥感找矿

资源开采

地质保障
智能穿爆
智能采运排

无人驾驶
智能辅助
灾害预警与防治

智能掘进
智能通风

物流运输

无人驾驶矿卡
智能皮带运输
智能调度

智能安全监控

人员行为识别
设备状态监测
环境风险预警
智能应急救援

智能选矿

品位智能预测
智能分选
选冶流程优化

经营管理

智能生产调度
智能运维管理
智能能耗管理

智慧医疗

智慧零售


智慧金融

智慧物流

智慧文旅

智慧采矿

大模型对哪些行业产生了影响？





知乎知学堂

「大模型应用开发工程师岗位」炙手可热!!!

最新

AI应用开发工程师 **30-50K·14薪**

北京 3-5年 本科

感兴趣 立即沟通

完善在线简历 新增附件简历

节日福利 团建聚餐 零食下午茶 餐补 带薪年假 ...

最新

AI应用开发工程师 **30-40K**

北京 5-10年 本科

感兴趣 立即沟通

五险一金 补充医疗保险 定期体检 年终奖

完善在线简历

最新

ai应用开发工程师 **20-40K**

北京 1-3年 本科

感兴趣 立即沟通

完善在线简历 新增附件简历

五险一金 补充医疗保险 定期体检 年终奖 绩效奖金

招聘中 猎头

大模型应用平台研发 **40-70K·16薪**

代招公司: 某500强上市公司 北京 5-10年 本科

感兴趣 立即沟通

模型工程研发工程师 **25-30K·15薪**

北京 5-10年 本科

感兴趣 立即沟通

交通补

2023年1月以来已增长了32倍

ai应用开发工程师 **25-50K**

北京 3-5年 硕士

感兴趣 立即沟通

职位描述

深度学习 大模型算法 强化学习 自然语言处理算法 图像算法 数据挖掘 C/C++ Python Golang

算法工程化经验

职位描述:

1.负责公司大模型架构的研发, 研究相关技术在公司业务的落地和解决方案, 解决系统高并发、高可靠性、高可扩展性等技术难关;

2.覆盖机器学习系统多个子方向领域的工作, 包括资源调度、模型训练、模型推理等;

3.负责机器学习系统前瞻技术的调研和引入, 包括最新硬件架构、异构计算系统、编译优化技术的引入落地;

4.与算法部门深度合作, 进行算法与系统的联合优化。

岗位要求:

1.车辆工程/计算机/通信及相关专业, 全日制统招本科及以上学历;

2.5年以上编程经验, 基础扎实, 熟悉C++/Python/Golang等至少一种编程语言, 熟悉多线程、多线程、异步编程方式;

3.至少熟练运用PyTorch/TensorFlow/PaddlePaddle等深度学习训练框架中的一种;

4.了解量化方式和优化方法, 能在模型训练及调优中熟练运用;

5.能使用单机多卡、多机多卡进行分布式训练;

职位描述

Agent python prompt

工作职责: 负责以大模型为基座的 agent 工作流应用开发

任职要求:

1、计算机相关专业硕士及以上学历, 本科阶段为985院校。

2、5年以内AI相关工作经验, 特别是多模态Agent、智能客服Agent相关工作经验者优先;

3、需要熟悉市场主流大模型与Llama3, RAG、多Agent并发、prompt 提示词, 工作经验者优先。

4、精通Python, 具备NLP技术的实际应用经验。

「大模型应用开发工程师」岗位要求

AI应用开发工程师 30-50K·14薪

北京 3-5年 本科

感兴趣

立即沟通

节日福利

团建聚餐

零食下午茶

餐补

带薪年假

...

完善在线简历

新增附件简历

职位描述

大数据处理工具(Spark/Hadoop/Hive)

模型加速/性能优化

Python

微信扫码分享

举报

岗位职责：

- 1、根据业务需求和应用场景，设计AI Agent，通过Prompt Engineering，使得Agent可以稳定、高效实现场景目标；
- 2、参与基于大模型的应用开发，进行应用搭建和优化；
- 3、基于AI能力，实现数据加工、数据提取、NL2SQL、RAG、问答等业务需求；
- 4、跟踪和研究大模型领域的最新技术动态和发展趋势，提出创新性的技术解决方案，提升模型在实际应用中的表现。

岗位要求：

- 1、国内外名校，计算机科学、人工智能、数据科学或相关专业的本科及以上学历；
- 2、熟练掌握 AI开发技巧，精通 Python 等编程语言，有良好的编程习惯和代码质量；
- 3、有基于大模型的应用开发经验，曾主导或参与过实际项目。具备开源大模型的开发或贡献经验；
- 4、熟悉指令工程（prompt engineering）、向量检索、RAG、任务规划等AI agent关键技术；
- 5、对AI有热情，熟悉AI技术发展、了解模型能力边界，具备AI功能设计的基本意识。

工资计算器

请输入税前月工资 元

计算

公司基本信息



天眼查

不需要融资

1000-9999人

互联网

「大模型应用开发工程师岗位」能力模型

能力层级	核心技能项	具体知识点
一、基础与架构 (地基)	1. 主流模型架构原理	Transformer、SFT（监督微调）、RLHF（基于人类反馈的强化学习）基础
	2. 推理优化与部署	vLLM推理加速、模型量化、Docker/K8s容器化部署
	3. 向量数据库	Milvus/Pinecone/Chroma 的使用与索引优化（配合Embedding）
二、核心应用开发 (主干)	4. 提示词工程	零样本/少样本、思维链（CoT）、结构化输出
	5. RAG 应用开发	包含 Embedding 选型、重排序（Rerank）、多路召回策略
	6. Agent 智能体开发	包含 Function Calling / Tool Use、Planning（规划）、记忆（Memory）管理
三、进阶调优与闭环 (顶层)	7. 模型微调（Fine-tuning）	LoRA/QLoRA 微调、数据处理与格式化
	8. 工程化框架	LangGraph / LangChain（作为连接以上所有模块的编排层）
	9. 评估与数据飞轮	自动化评估指标（RAGAS）、Bad Case分析、数据回流策略

二、想要胜任这个岗位你需要会的**AI**技术

Prompt、RAG、Agent、Fine tuning


什么是 Prompt
提示词工程

什么是 RAG
通过从外部资源或数据库中纳入相关信息来实现

什么是 Agent
智能体

什么是 Fine tuning
微调

RAG检索增强生成架构设计



➤ RAG 实现技术重点

- 相似度检索
- 离线数据装载

LLM Wiki: 具有Agentic进化能力的图结构知识库



LLM: 知识固定，有截止日期

- 1、只懂得通用知识，不懂企业内部的私有知识
- 2、即便使用 Fine-tuning 或 RAG，仍无法解决更新问题
- 3、现有技术过度依赖人力整理企业知识

User Prompt → RAG → System Prompt →
LLM → Answer



LLM Wiki: 知识库的自我迭代

更直观: 知识目录、实体跳转、组合检索

更智能: 自我纠错、自我更新

图结构: 效率高、可推理

系统化: 可编译、可重启

Agentic: 可与 Loop Engineering 无缝衔接

从“超级记忆”到“知识推理”的回答能力跃迁

LLM Wiki 的三层架构：从数据到智能

Karpathy提出的LLM Wiki三层架构，将企业知识系统从简单的“存文档”升级为类似“编译器”的智能系统，实现了从原始数据到结构化知识的质变，是AI时代构建企业知识库的新思路。

Raw Layer (原始数据湖)

事实来源 (Source of Truth): 包含文档 (PDF/Word)、代码(Git)、数据库、IM记录等所有原始、未加工数据。

- 特点：数据混乱、不可控，不适合直接处理。
- 价值：保留原始事实，为回溯提供依据。

Wiki Layer (编译输出层)

核心知识层： AI“编译”后的结构化知识，含页面、摘要、实体、双向链接及关系图等。

- 本质：“知识编译器”
- 价值：将原始数据转化为LLM可高效利用的预编译知识。

Schema Layer (控制协议)

系统规则层： 定义知识宇宙的操作规范，包括页面模版、实体Schema、命名规范、链接规则等。

- 价值：统一知识表示，避免实体不统一、命名混乱，确保系统长期可维护。

核心转变： 从 **Query-time Intelligence** (查询时理解) 转向 **Ingest-time Intelligence** (摄入时编译)。这一架构的本质，是将“企业知识库”升级为“AI时代的知识编译系统”。

LLM Wiki: 具有Agentic进化能力的图结构知识库



LLM: 知识固定，有截止日期

- 1、只懂得通用知识，不懂企业内部的私有知识
- 2、即便使用 Fine-tuning 或 RAG，仍无法解决更新问题
- 3、现有技术过度依赖人力整理企业知识

User Prompt → RAG → System Prompt →
LLM → Answer



LLM Wiki: 知识库的自我迭代

更直观: 知识目录、实体跳转、组合检索

更智能: 自我纠错、自我更新

图结构: 效率高、可推理

系统化: 可编译、可重启

Agentic: 可与 Loop Engineering 无缝衔接

从“超级记忆”到“知识推理”的回答能力跃迁

LLM Wiki 的三层架构：从数据到智能

Karpathy提出的LLM Wiki三层架构，将企业知识系统从简单的“存文档”升级为类似“编译器”的智能系统，实现了从原始数据到结构化知识的质变，是AI时代构建企业知识库的新思路。

Raw Layer (原始数据湖)

事实来源 (Source of Truth): 包含文档 (PDF/Word)、代码(Git)、数据库、IM记录等所有原始、未加工数据。

- 特点：数据混乱、不可控，不适合直接处理。
- 价值：保留原始事实，为回溯提供依据。

Wiki Layer (编译输出层)

核心知识层： AI“编译”后的结构化知识，含页面、摘要、实体、双向链接及关系图等。

- 本质：“知识编译器”
- 价值：将原始数据转化为LLM可高效利用的预编译知识。

Schema Layer (控制协议)

系统规则层： 定义知识宇宙的操作规范，包括页面模版、实体Schema、命名规范、链接规则等。

- 价值：统一知识表示，避免实体不统一、命名混乱，确保系统长期可维护。

核心转变： 从 **Query-time Intelligence** (查询时理解) 转向 **Ingest-time Intelligence** (摄入时编译)。这一架构的本质，是将“企业知识库”升级为“AI时代的知识编译系统”。

LLM Wiki 涉及到的应用技术

模块	Vibe Coding	Prompt Engineering	Loop Engineering	Context Engineering	Embedding	Search
文档格式处理	✓					
摘要与目录	✓	✓		✓		
实体提取	✓	✓	✓			
知识更新	✓	✓	✓			
任务理解		✓			✓	✓
寻找答案	✓	✓	✓	✓	✓	✓
任务终止		✓				

LLM Wiki 涉及到的多Agent技术


- 1、定期扫描原始信息是否有更新
- 2、编译新知识，更新 LLM Wiki
- 3、推理延伸产生更多知识
- 4、知识验证、推理检查
- 5、搜索
- 6、用户对话

多Agent协作

多Agent模型（Multi-Agent Model）是一种分布式人工智能模型，由多个智能体（Agent）组成，每个Agent都具有自主决策和交互能力，能够相互协作、竞争或协商以完成共同或各自的任务。

上下级协同


Hierarchical Collaboration



适合拆解的复杂任务

师生式协同


Master-Disciple Collaboration



难以拆解的复杂任务

竞争式协同

Competitive Collaboration



开放性的复杂任务

LLM Based Agent

从无状态，到特定状态的定义和识别

什么是无状态？什么是有状态？

什么是连续？什么是离散？

LLM Based Agent

从无状态，到特定状态的定义和识别

什么是无状态？什么是有状态？

什么是连续？什么是离散？

无状态

问：中国代表团在2024巴黎奥运会的表现如何？

答：中国代表团在2024年巴黎奥运会上的表现非常出色，取得了令人瞩目的成绩。根据最新的报道，中国代表团在本届奥运会上共收获了22金22银16铜，总计59枚奖牌，位列金牌榜的第二位。中国运动员在多个项目中表现出色，为国家和人民赢得了荣誉。

有状态

问：中国代表团在2024巴黎奥运会的表现如何？

答：

金牌： 22

银牌： 22

铜牌： 16

LLM Based Agent

从无状态，到特定状态的定义和识别

什么是无状态？什么是有状态？

什么是连续？什么是离散？

连续



离散

赤
橙
黄
绿
青
蓝
紫

LLM Based Agent

从无状态，到特定状态的定义和识别

什么是无状态？什么是有状态？

什么是连续？什么是离散？

无状态、连续

Prompt: Hey Siri, 帮我用美团外卖点两份热干面和可乐,
就平时总点的那家, 送公司, 放外卖柜。

有状态、离散

```
{  
  "App": "美团",  
  "Orders": ["热干面", "可乐"],  
  "Numbers": [ 2, 2 ]  
  "Location": "公司"  
  "Notes": "放外卖柜"  
}
```

LLM Based Agent

从无状态，到特定状态的定义和识别

什么是无状态？什么是有状态？

什么是连续？什么是离散？

人类智能，将连续性进行离散化，从而完成了工业化。比如音乐。

Agent，将无状态输出的大模型，变成了有状态输出的逻辑大脑，目标也是工业化。

用好Agent的关键，思考哪些东西值得被离散化、状态化。

不断测试大模型的能力，并研究如何提高状态判断的准确度。

Step 1

**Collect demonstration data,
and train a supervised policy.**


A prompt is
sampled from our
prompt dataset.

A labeler
demonstrates the
desired output
behavior.

This data is used
to fine-tune GPT-3
with supervised
learning.

Explain the moon
landing to a 6 year old

Some people went
to the moon...



Step 2

**Collect comparison data,
and train a reward model.**

A prompt and
several model
outputs are
sampled.


A labeler ranks
the outputs from
best to worst.

This data is used
to train our
reward model.

Explain the moon
landing to a 6 year old

A Explain gravity...
B Explain war...
C Moon is natural
satellite of...
D People went to
the moon...

D > C > A = B



Step 3

**Optimize a policy against
the reward model using
reinforcement learning.**

第一步：收集示范数据，
并制定监督政策。—准备
了很多prompt

第二步：收集比较数据，
并训练奖励模型。—Fine-
tuning

第三步：使用强化学习针
对奖励模型优化策略。

To train the very first InstructGPT models, we asked labelers to write prompts themselves. This is because we needed an initial source of instruction-like prompts to bootstrap the process, and these kinds of prompts weren't often submitted to the regular GPT-3 models on the API. We asked labelers to write three kinds of prompts:

- **Plain:** We simply ask the labelers to come up with an arbitrary task, while ensuring the tasks had sufficient diversity.
- **Few-shot:** We ask the labelers to come up with an instruction, and multiple query/response pairs for that instruction.
- **User-based:** We had a number of use-cases stated in waitlist applications to the OpenAI API. We asked labelers to come up with prompts corresponding to these use cases.

From these prompts, we produce three different datasets used in our fine-tuning procedure: (1) our SFT dataset, with labeler demonstrations used to train our SFT models, (2) our RM dataset, with labeler rankings of model outputs used to train our RMs, and (3) our PPO dataset, without any human labels, which are used as inputs for RLHF fine-tuning. The SFT dataset contains about 13k training prompts (from the API and labeler-written), the RM dataset has 33k training prompts (from the API and labeler-written), and the PPO dataset has 31k training prompts (only from the API). More details on dataset sizes are provided in Table 6.

Fine-tuning models

Create your own custom models by fine-tuning our base models with your training data. Once you fine-tune a model, you'll be billed only for the tokens you use in requests to that model.

[Learn more about fine-tuning ↗](#)

Model	Training	Usage
Ada	\$0.0004 / 1K tokens	\$0.0016 / 1K tokens
Babbage	\$0.0006 / 1K tokens	\$0.0024 / 1K tokens
Curie	\$0.0030 / 1K tokens	\$0.0120 / 1K tokens
Davinci	\$0.0300 / 1K tokens	\$0.1200 / 1K tokens

Embedding models

Build advanced search, clustering, topic modeling, and classification functionality with our embeddings offering.

[Learn more about embeddings ↗](#)

Step 1

**Collect demonstration data,
and train a supervised policy.**


A prompt is
sampled from our
prompt dataset.

A labeler
demonstrates the
desired output
behavior.

This data is used
to fine-tune GPT-3
with supervised
learning.

Explain the moon
landing to a 6 year old

Some people went
to the moon...



Step 2

**Collect comparison data,
and train a reward model.**

A prompt and
several model
outputs are
sampled.


A labeler ranks
the outputs from
best to worst.

This data is used
to train our
reward model.

Explain the moon
landing to a 6 year old

A Explain gravity... B Explain war...
C Moon is natural satellite of... D People went to the moon...

D > C > A = B



Step 3

**Optimize a policy against
the reward model using
reinforcement learning.**

第一步：收集示范数据，
并制定监督政策。—准备
了很多prompt

第二步：收集比较数据，
并训练奖励模型。—Fine-
tuning

第三步：使用强化学习针
对奖励模型优化策略。

微调前

 孩子在学校由于同学拉扯导致受伤了，我怎么索赔？

 我很抱歉听到您的孩子在学校发生了受伤的情况。要进行索赔，您可以考虑以下步骤：

1. 确保孩子的安全和健康：首先，确保您的孩子得到适当的医疗照顾。确保他们的伤势得到妥善处理，并保存与伤情相关的所有医疗记录、收据和报告。
2. 了解学校政策：仔细研究学校的政策，特别是与学生安全和责任有关的政策。这些信息可能包含在学校的手册或网站上。了解学校的保险覆盖范围以及索赔程序。
3. 与学校联系：与学校的行政人员、校长或教导主任等相关人员取得联系，向他们详细描述发生的事件。提供医疗记录和相关证据，说明您的孩子受伤的原因以及可能存在的责任。
4. 寻求法律咨询：如果您认为学校对事件负有责任但学校未能采取适当行动，您可能需要咨询一位律师。专业的法律咨询可以帮助您了解您的权利，并指导您采取进一步的法律行动。
5. 提起索赔：根据您所在地区的法律规定，可能需要填写索赔申请表或提交索赔文件。这通常需要详细描述事件的经过、伤害的性质和严重程度，以及您所寻求的赔偿金额。确保您按照规定的时间限制提交索赔申请。

重要的是要注意，索赔程序可能因地区而异，所以最好在与学校沟通之前咨询一位当地律师，以确保您按照正确的程序进行索赔。

没有给出索赔的相应法律依据，也没有给出**具体的索赔措施**，处理措施也比较**笼统模糊**。

微调后

 孩子在学校由于同学拉扯导致受伤了，我怎么索赔？

 根据《中华人民共和国民法典》第一千二百零一条和第一千一百八十八条的规定，如果孩子在学校由于同学拉扯导致受伤，属于人身损害，一般由侵权人承担侵权责任。如果侵权人是无民事行为能力人或者限制民事行为能力人，那么由其监护人承担侵权责任。同时，如果学校未尽到管理职责，学校也应当承担相应的补充责任。

因此，您可以先与致害学生的家长以及学校协商解决办法。如果协商不成，您可以将致害学生的家长和学校作为共同被告向法院起诉维权，要求索赔。

请注意，以上回答仅供参考，具体的法律问题需要根据实际情况进行具体分析和判断。建议您咨询专业律师以获取更准确的法律意见。

① ② ③ ④

精准的给出了索赔对象、操作措施和法律依据。操作措施给出了协商和起诉，起诉二者为共同被告非常准确，指引性较强。

入职AI应用开发的必备应用技能

段位	年薪	Prompt	Agent	RAG	Fine tune	垂直行业LLM
最初级	5-15w	优秀				
初级	10-30w	优秀	优秀			
中级	30-80w	优秀	优秀	优秀	合格	
高级	100w起	优秀	优秀	优秀	优秀	
顶级	200w起	-	-	-	优秀	优秀

重点： 深度理解原理+应用技术+项目实操经验

三、岗位就业必须要懂的算法原理

大模型应用开发工程师就业必懂算法原理

无需任何算法基础，初中数学的知识储备即可

Next Token Prediction


理解现有的文字，预测下一个字

简化理解LLM的运行模型

LLM运行模式：Next Token Prediction

46秒40！北京时间8月1日凌晨，在刚刚结束的巴黎奥运会游泳项目男子100米自由泳决赛中，中国选手潘展乐拿下冠军，同时刷新该项目同样由他创造的世界纪录（46秒80），这也是中国游泳队在本届奥运会的首枚金牌。

赛后接受采访时，潘展乐难掩激动，“第一天4X100游完后，我在下面跟查尔默斯打招呼，他一点都不理我，包括美国队的阿莱克谢，我们训练的时候教练在岸上，他那种滚翻直接往教练身上溅水花，感觉有点看不起我们。能说吗？今天终于把他们所有人都拿下了，而且在这么难游的池子里打破世界纪录。真是非常好的表现，我给中国队拿了很棒的一个开门红。”被问及“突破”的方法，潘展乐称，“憋着一口气，我们国家这么多人，这么多人的希望，在下水的前一刻我感受到了。”



▲2024年8月1日，中国选手潘展乐（右二）在巴黎奥运会游泳项目男子100米自由泳决赛中率先触线 图/新华社

模型训练

Ground Truth

刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！
46秒40！北京时间8月1日凌晨，在刚刚结束的巴黎奥运会游泳项目男子100米自由泳决赛中，中国选手潘展乐拿下冠军，同时刷新该项目同样由他创造的世界纪录（46秒80），这也是中国游泳队在本届奥运会的首枚金牌。

Next Token Prediction


刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！
46秒40！北京时
刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！
46秒40！北京时
刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！
46秒40！北京时间8
.....
.....

简化理解LLM的运行模型

LLM运行模式：Next Token Prediction

46秒40！北京时间8月1日凌晨，在刚刚结束的巴黎奥运会游泳项目男子100米自由泳决赛中，中国选手潘展乐拿下冠军，同时刷新该项目同样由他创造的世界纪录（46秒80），这也是中国游泳队在本届奥运会的首枚金牌。

赛后接受采访时，潘展乐难掩激动，“第一天4X100游完后，我在下面跟查尔默斯打招呼，他一点都不理我，包括美国队的阿莱克谢，我们训练的时候教练在岸上，他那种滚翻直接往教练身上溅水花，感觉有点看不起我们。能说吗？今天终于把他们所有人都拿下了，而且在这么难游的池子里打破世界纪录。真是非常好的表现，我给中国队拿了很棒的一个开门红。”被问及“突破”的方法，潘展乐称，“憋着一口气，我们国家这么多人，这么多人的希望，在下水的前一刻我感受到了。”



▲2024年8月1日，中国选手潘展乐（右二）在巴黎奥运会游泳项目男子100米自由泳决赛中率先触线 图/新华社

模型运行

Prompt

刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！

开始续写，每次只写一个字


刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！

简化理解LLM的运行模型

LLM运行模式：Next Token Prediction

46秒40！北京时间8月1日凌晨，在刚刚结束的巴黎奥运会游泳项目男子100米自由泳决赛中，中国选手潘展乐拿下冠军，同时刷新该项目同样由他创造的世界纪录（46秒80），这也是中国游泳队在本届奥运会的首枚金牌。

赛后接受采访时，潘展乐难掩激动，“第一天4X100游完后，我在下面跟查尔默斯打招呼，他一点都不理我，包括美国队的阿莱克谢，我们训练的时候教练在岸上，他那种滚翻直接往教练身上溅水花，感觉有点看不起我们。能说吗？今天终于把他们所有人都拿下了，而且在这么难游的池子里打破世界纪录。真是非常好的表现，我给中国队拿了很棒的一个开门红。”被问及“突破”的方法，潘展乐称，“憋着一口气，我们国家这么多人，这么多人的希望，在下水的前一刻我感受到了。”



▲2024年8月1日，中国选手潘展乐（右二）在巴黎奥运会游泳项目男子100米自由泳决赛中率先触线 图/新华社

模型运行

Prompt

刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！

开始续写，每次只写一个字

刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！


北

简化理解LLM的运行模型

LLM运行模式：Next Token Prediction

46秒40！北京时间8月1日凌晨，在刚刚结束的巴黎奥运会游泳项目男子100米自由泳决赛中，中国选手潘展乐拿下冠军，同时刷新该项目同样由他创造的世界纪录（46秒80），这也是中国游泳队在本届奥运会的首枚金牌。

赛后接受采访时，潘展乐难掩激动，“第一天4X100游完后，我在下面跟查尔默斯打招呼，他一点都不理我，包括美国队的阿莱克谢，我们训练的时候教练在岸上，他那种滚翻直接往教练身上溅水花，感觉有点看不起我们。能说明吗？今天终于把他们所有人都拿下了，而且在这么难游的池子里打破世界纪录。真是非常好的表现，我给中国队拿了很棒的一个开门红。”被问及“突破”的方法，潘展乐称，“憋着一口气，我们国家这么多人，这么多人的希望，在下水的前一刻我感受到了。”



▲2024年8月1日，中国选手潘展乐（右二）在巴黎奥运会游泳项目男子100米自由泳决赛中率先触线 图/新华社

模型运行

Prompt

刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！

开始续写，每次只写一个字

刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！


北京

简化理解LLM的运行模型

LLM运行模式：Next Token Prediction

46秒40！北京时间8月1日凌晨，在刚刚结束的巴黎奥运会游泳项目男子100米自由泳决赛中，中国选手潘展乐拿下冠军，同时刷新该项目同样由他创造的世界纪录（46秒80），这也是中国游泳队在本届奥运会的首枚金牌。

赛后接受采访时，潘展乐难掩激动，“第一天4X100游完后，我在下面跟查尔默斯打招呼，他一点都不理我，包括美国队的阿莱克谢，我们训练的时候教练在岸上，他那种滚翻直接往教练身上溅水花，感觉有点看不起我们。能说明？今天终于把他们所有人都拿下了，而且在这么难游的池子里打破世界纪录。真是非常好的表现，我给中国队拿了很棒的一个开门红。”被问及“突破”的方法，潘展乐称，“憋着一口气，我们国家这么多人，这么多人的希望，在下水的前一刻我感受到了。”



▲2024年8月1日，中国选手潘展乐（右二）在巴黎奥运会游泳项目男子100米自由泳决赛中率先触线 图/新华社

模型运行

Prompt

刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！

开始续写，每次只写一个字

刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！


北京时

简化理解LLM的运行模型

LLM运行模式：Next Token Prediction

46秒40！北京时间8月1日凌晨，在刚刚结束的巴黎奥运会游泳项目男子100米自由泳决赛中，中国选手潘展乐拿下冠军，同时刷新该项目同样由他创造的世界纪录（46秒80），这也是中国游泳队在本届奥运会的首枚金牌。

赛后接受采访时，潘展乐难掩激动，“第一天4X100游完后，我在下面跟查尔默斯打招呼，他一点都不理我，包括美国队的阿莱克谢，我们训练的时候教练在岸上，他那种滚翻直接往教练身上溅水花，感觉有点看不起我们。能说吗？今天终于把他们所有人都拿下了，而且在这么难游的池子里打破世界纪录。真是非常好的表现，我给中国队拿了很棒的一个开门红。”被问及“突破”的方法，潘展乐称，“憋着一口气，我们国家这么多人，这么多人的希望，在下水的前一刻我感受到了。”



▲2024年8月1日，中国选手潘展乐（右二）在巴黎奥运会游泳项目男子100米自由泳决赛中率先触线 图/新华社

模型运行

Prompt

刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！

开始续写，每次只写一个字

刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！


北京时间

简化理解LLM的运行模型

LLM运行模式：Next Token Prediction

46秒40！北京时间8月1日凌晨，在刚刚结束的巴黎奥运会游泳项目男子100米自由泳决赛中，中国选手潘展乐拿下冠军，同时刷新该项目同样由他创造的世界纪录（46秒80），这也是中国游泳队在本届奥运会的首枚金牌。

赛后接受采访时，潘展乐难掩激动，“第一天4X100游完后，我在下面跟查尔默斯打招呼，他一点都不理我，包括美国队的阿莱克谢，我们训练的时候教练在岸上，他那种滚翻直接往教练身上溅水花，感觉有点看不起我们。能说明？今天终于把他们所有人都拿下了，而且在这么难游的池子里打破世界纪录。真是非常好的表现，我给中国队拿了很棒的一个开门红。”被问及“突破”的方法，潘展乐称，“憋着一口气，我们国家这么多人，这么多人的希望，在下水的前一刻我感受到了。”



▲2024年8月1日，中国选手潘展乐（右二）在巴黎奥运会游泳项目男子100米自由泳决赛中率先触线 图/新华社

模型运行

Prompt

刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！

开始续写，每次只写一个字

刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！


北京时间8

简化理解LLM的运行模型

LLM运行模式：Next Token Prediction

46秒40！北京时间8月1日凌晨，在刚刚结束的巴黎奥运会游泳项目男子100米自由泳决赛中，中国选手潘展乐拿下冠军，同时刷新该项目同样由他创造的世界纪录（46秒80），这也是中国游泳队在本届奥运会的首枚金牌。

赛后接受采访时，潘展乐难掩激动，“第一天4X100游完后，我在下面跟查尔默斯打招呼，他一点都不理我，包括美国队的阿莱克谢，我们训练的时候教练在岸上，他那种滚翻直接往教练身上溅水花，感觉有点看不起我们。能说明？今天终于把他们所有人都拿下了，而且在这么难游的池子里打破世界纪录。真是非常好的表现，我给中国队拿了很棒的一个开门红。”被问及“突破”的方法，潘展乐称，“憋着一口气，我们国家这么多人，这么多人的希望，在下水的前一刻我感受到了。”



▲2024年8月1日，中国选手潘展乐（右二）在巴黎奥运会游泳项目男子100米自由泳决赛中率先触线 图/新华社

模型运行

Prompt

刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！

开始续写，每次只写一个字

刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！


北京时间8月

简化理解LLM的运行模型

LLM运行模式：Next Token Prediction

46秒40！北京时间8月1日凌晨，在刚刚结束的巴黎奥运会游泳项目男子100米自由泳决赛中，中国选手潘展乐拿下冠军，同时刷新该项目同样由他创造的世界纪录（46秒80），这也是中国游泳队在本届奥运会的首枚金牌。

赛后接受采访时，潘展乐难掩激动，“第一天4X100游完后，我在下面跟查尔默斯打招呼，他一点都不理我，包括美国队的阿莱克谢，我们训练的时候教练在岸上，他那种滚翻直接往教练身上溅水花，感觉有点看不起我们。能说吗？今天终于把他们所有人都拿下了，而且在这么难游的池子里打破世界纪录。真是非常好的表现，我给中国队拿了很棒的一个开门红。”被问及“突破”的方法，潘展乐称，“憋着一口气，我们国家这么多人，这么多人的希望，在下水的前一刻我感受到了。”



▲2024年8月1日，中国选手潘展乐（右二）在巴黎奥运会游泳项目男子100米自由泳决赛中率先触线 图/新华社

模型运行

Prompt

刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！

开始续写，每次只写一个字

刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！


北京时间8月1

简化理解LLM的运行模型

LLM运行模式：Next Token Prediction

46秒40！北京时间8月1日凌晨，在刚刚结束的巴黎奥运会游泳项目男子100米自由泳决赛中，中国选手潘展乐拿下冠军，同时刷新该项目同样由他创造的世界纪录（46秒80），这也是中国游泳队在本届奥运会的首枚金牌。

赛后接受采访时，潘展乐难掩激动，“第一天4X100游完后，我在下面跟查尔默斯打招呼，他一点都不理我，包括美国队的阿莱克谢，我们训练的时候教练在岸上，他那种滚翻直接往教练身上溅水花，感觉有点看不起我们。能说吗？今天终于把他们所有人都拿下了，而且在这么难游的池子里打破世界纪录。真是非常好的表现，我给中国队拿了很棒的一个开门红。”被问及“突破”的方法，潘展乐称，“憋着一口气，我们国家这么多人，这么多人的希望，在下水的前一刻我感受到了。”



▲2024年8月1日，中国选手潘展乐（右二）在巴黎奥运会游泳项目男子100米自由泳决赛中率先触线 图/新华社

模型运行

Prompt

刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！

开始续写，每次只写一个字

刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！


北京时间8月1日

简化理解LLM的运行模型

LLM运行模式：Next Token Prediction

46秒40！北京时间8月1日凌晨，在刚刚结束的巴黎奥运会游泳项目男子100米自由泳决赛中，中国选手潘展乐拿下冠军，同时刷新该项目同样由他创造的世界纪录（46秒80），这也是中国游泳队在本届奥运会的首枚金牌。

赛后接受采访时，潘展乐难掩激动，“第一天4X100游完后，我在下面跟查尔默斯打招呼，他一点都不理我，包括美国队的阿莱克谢，我们训练的时候教练在岸上，他那种滚翻直接往教练身上溅水花，感觉有点看不起我们。能说吗？今天终于把他们所有人都拿下了，而且在这么难游的池子里打破世界纪录。真是非常好的表现，我给中国队拿了很棒的一个开门红。”被问及“突破”的方法，潘展乐称，“憋着一口气，我们国家这么多人，这么多人的希望，在下水的前一刻我感受到了。”



▲2024年8月1日，中国选手潘展乐（右二）在巴黎奥运会游泳项目男子100米自由泳决赛中率先触线 图/新华社

模型运行

Prompt

刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！

开始续写，每次只写一个字

刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！


北京时间8月1日凌晨

简化理解LLM的运行模型

LLM运行模式：Next Token Prediction

46秒40！北京时间8月1日凌晨，在刚刚结束的巴黎奥运会游泳项目男子100米自由泳决赛中，中国选手潘展乐拿下冠军，同时刷新该项目同样由他创造的世界纪录（46秒80），这也是中国游泳队在本届奥运会的首枚金牌。

赛后接受采访时，潘展乐难掩激动，“第一天4X100游完后，我在下面跟查尔默斯打招呼，他一点都不理我，包括美国队的阿莱克谢，我们训练的时候教练在岸上，他那种滚翻直接往教练身上溅水花，感觉有点看不起我们。能说吗？今天终于把他们所有人都拿下了，而且在这么难游的池子里打破世界纪录。真是非常好的表现，我给中国队拿了很棒的一个开门红。”被问及“突破”的方法，潘展乐称，“憋着一口气，我们国家这么多人，这么多人的希望，在下水的前一刻我感受到了。”



▲2024年8月1日，中国选手潘展乐（右二）在巴黎奥运会游泳项目男子100米自由泳决赛中率先触线 图/新华社

模型运行

Prompt

刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！

开始续写，每次只写一个字

刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！


北京时间8月1日凌晨

简化理解LLM的运行模型

LLM运行模式：Next Token Prediction

46秒40！北京时间8月1日凌晨，在刚刚结束的巴黎奥运会游泳项目男子100米自由泳决赛中，中国选手潘展乐拿下冠军，同时刷新该项目同样由他创造的世界纪录（46秒80），这也是中国游泳队在本届奥运会的首枚金牌。

赛后接受采访时，潘展乐难掩激动，“第一天4X100游完后，我在下面跟查尔默斯打招呼，他一点都不理我，包括美国队的阿莱克谢，我们训练的时候教练在岸上，他那种滚翻直接往教练身上溅水花，感觉有点看不起我们。能说吗？今天终于把他们所有人都拿下了，而且在这么难游的池子里打破世界纪录。真是非常好的表现，我给中国队拿了很棒的一个开门红。”被问及“突破”的方法，潘展乐称，“憋着一口气，我们国家这么多人，这么多人的希望，在下水的前一刻我感受到了。”



▲2024年8月1日，中国选手潘展乐（右二）在巴黎奥运会游泳项目男子100米自由泳决赛中率先触线 图/新华社

模型运行

Prompt

刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！

开始续写，每次只写一个字

刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！


北京时间8月1日凌晨，

简化理解LLM的运行模型

LLM运行模式：Next Token Prediction

46秒40！北京时间8月1日凌晨，在刚刚结束的巴黎奥运会游泳项目男子100米自由泳决赛中，中国选手潘展乐拿下冠军，同时刷新该项目同样由他创造的世界纪录（46秒80），这也是中国游泳队在本届奥运会的首枚金牌。

赛后接受采访时，潘展乐难掩激动，“第一天4X100游完后，我在下面跟查尔默斯打招呼，他一点都不理我，包括美国队的阿莱克谢，我们训练的时候教练在岸上，他那种滚翻直接往教练身上溅水花，感觉有点看不起我们。能说吗？今天终于把他们所有人都拿下了，而且在这么难游的池子里打破世界纪录。真是非常好的表现，我给中国队拿了很棒的一个开门红。”被问及“突破”的方法，潘展乐称，“憋着一口气，我们国家这么多人，这么多人的希望，在下水的前一刻我感受到了。”



▲2024年8月1日，中国选手潘展乐（右二）在巴黎奥运会游泳项目男子100米自由泳决赛中率先触线 图/新华社

模型运行

Prompt

刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！

开始续写，每次只写一个字

刷新100米自由泳世界纪录！潘展乐为中国泳军拿下首金！

北京时间8月1日凌晨，参加男子100米自由泳的潘展乐像一道闪电，划破了巴黎的夜空——他以46秒40打破世界纪录的成绩赢得冠军！

玩转这些场景必须要懂的算法原理

无需任何算法基础，初中数学的知识储备即可

Next Token Prediction

理解现有的文字，预测下一个字

必须要掌握的几个概念

向量、空间、特征

必须要掌握的几个概念

向量、空间、特征

什么是向量

1维向量：坐标 $[3]$ ，一维空间中的一个点

2维向量：坐标 $[2, 5]$ ，二维空间中的一个点

3维向量：坐标 $[-1, 4, -2.5]$ ，三维空间中的一个点

...

...

512维向量：坐标 $[3, 5, -2, \dots]$ ，512维空间中的一个点

...

...

1024维向量：坐标 $[6, 1.2, -2, \dots]$ ，1024维空间中的一个点

...

...

这东西能有什么用？

必须要掌握的几个概念

向量、空间、特征

那特征又是什么？

这个3000维的空间并不是我们想要的（向量无法描述任何文字之间的区别或关系）

我们希望设计一个空间，空间中的点（向量）可以描述文字的某些特性（向量具有特征表示能力）

Embedding

创造一个新的数学空间，每个字（或英文单词）在空间中，都能找到自己的特征表示

GPT 3/3.5，空间/向量维度：12288维

比如，我，【7, 4, 6, -2, 11, -1.2, 6.3, 0.56,】总计12288个坐标数值

必须要掌握的几个概念

向量、空间、特征

那特征又是什么？

这个3000维的空间并不是我们想要的（向量无法描述任何文字之间的区别或关系）

我们希望设计一个空间，空间中的点（向量）可以描述文字的某些特性（向量具有特征表示能力）

Embedding

创造一个新的数学空间，每个字（或英文单词）在空间中，都能找到自己的特征表示

GPT 3/3.5，空间/向量维度：12288维

比如，我，【7, 4, 6, -2, 11, -1.2, 6.3, 0.56,】总计12288个坐标数值

计算相似度（距离）

国王：向量a

皇帝：向量b

君王：向量c

狗：向量d

猫：向量e

蛇：向量f

鳄鱼：向量g

数学或逻辑计算

国王：向量a

女王：向量b

国王 - 男人 + 女人 $\approx$ 女王

男人：向量e

女人：向量f

必须要掌握的几个概念

向量、空间、特征

这个Embedding空间中的向量是否有可能表示句子的特征？

Embedding

创造一个新的数学空间，每个字（或英文单词）在空间中，都能找到自己的特征表示

GPT 3/3.5，空间/向量维度：12288维

比如，我，【7, 4, 6, -2, 11, -1.2, 6.3, 0.56,】总计12288个坐标数值

我们用了12288维的空间，表示了3000个汉字？大量的坐标值是0？

向量a代表“我”：【7, 4, 6, -2, 11, -1.2, 6.3, 0.56,】总计12288个坐标数值

向量b代表“们”：【2, 0, 1, 2.4, 1.5, -2, -3, 1.9,】总计12288个坐标数值

那a+b的结果能代表“我们”么？和“we”这个单词的向量相似度高么？

必须要掌握的几个概念

向量、空间、特征

这个Embedding空间中的向量是否有可能表示句子的特征？

Embedding

创造一个新的数学空间，每个字（或英文单词）在空间中，都能找到自己的特征表示

GPT 3/3.5，空间/向量维度：12288维

比如，我，【7, 4, 6, -2, 11, -1.2, 6.3, 0.56,】总计12288个坐标数值


我们用了个12288维的空间，表示了3000个汉字？大量的坐标值是0？

向量a代表“我”：【7, 4, 6, -2, 11, -1.2, 6.3, 0.56,】总计12288个坐标数值

向量b代表“们”：【2, 0, 1, 2.4, 1.5, -2, -3, 1.9,】总计12288个坐标数值

那a+b的结果能代表“我们”么？和“we”这个单词的向量相似度高么？

那“我们是共产主义接班人”，就是把这这些字的向量全部加起来么？





知乎知学堂

2017年 Transformer 横空出世

Attention Is All You Need

Ashish Vaswani*

Google Brain

avaswani@google.com

Noam Shazeer*

Google Brain

noam@google.com

Niki Parmar*

Google Research

nikip@google.com

Jakob Uszkoreit*

Google Research

usz@google.com

Llion Jones*

Google Research

llion@google.com

Aidan N. Gomez*[†]

University of Toronto

aidan@cs.toronto.edu

Lukasz Kaiser*

Google Brain

lukaszkaizer@google.com

Illia Polosukhin*[‡]

illia.polosukhin@gmail.com

Transformer 编码器&解码器




Figure 1: The Transformer - model architecture.

Transformer 编码器&解码器

Encoder&Decoder

在这个12288维空间中进行Encoding (Self Attention)

计算向量之间的相关度，根据相关度系数加权求和

我 向量a

a1

们 向量b

是 向量c

共 向量d

产 向量e

主 向量f

义 向量g

接 向量h

班 向量i

人 向量j

Transformer 编码器&解码器

Encoder&Decoder

在这个12288维空间中进行Encoding (Self Attention)

计算向量之间的相关度，根据相关度系数加权求和

我 向量a  a1

们 向量b

是 向量c

共 向量d

产 向量e

主 向量f

义 向量g

接 向量h

班 向量i

人 向量j

Transformer 编码器&解码器

Encoder&Decoder

在这个12288维空间中进行Encoding (Self Attention)

计算向量之间的相关度，根据相关度系数加权求和

我 向量a
们 向量b
是 向量c
共 向量d
产 向量e
主 向量f
义 向量g
接 向量h
班 向量i
人 向量j



Transformer 编码器&解码器

Encoder&Decoder

在这个12288维空间中进行Encoding (Self Attention)

计算向量之间的相关度，根据相关度系数加权求和

我 向量a
们 向量b
是 向量c
共 向量d
产 向量e
主 向量f
义 向量g
接 向量h
班 向量i
人 向量j



Transformer 编码器&解码器

Encoder&Decoder

在这个12288维空间中进行Encoding (Self Attention)

计算向量之间的相关度，根据相关度系数加权求和

我 向量a
们 向量b
是 向量c
共 向量d
产 向量e
主 向量f
义 向量g
接 向量h
班 向量i
人 向量j




Transformer 编码器&解码器

Encoder&Decoder

在这个12288维空间中进行Encoding (Self Attention)

计算向量之间的相关度，根据相关度系数加权求和



Transformer 编码器&解码器

Encoder&Decoder

在这个12288维空间中进行Encoding (Self Attention)

计算向量之间的相关度，根据相关度系数加权求和

我 向量a

a1

们 向量b

b1

是 向量c

共 向量d

产 向量e

主 向量f

义 向量g

接 向量h

班 向量i

人 向量j

Transformer 编码器&解码器

Encoder&Decoder

在这个12288维空间中进行Encoding (Self Attention)

计算向量之间的相关度，根据相关度系数加权求和

我 向量a
们 向量b
是 向量c
共 向量d
产 向量e
主 向量f
义 向量g
接 向量h
班 向量i
人 向量j



The diagram shows two blue arrows originating from the right side of the text '我 向量a' and '们 向量b'. These arrows point towards the labels 'a1' and 'b1' respectively, indicating a transformation or combination of the vectors.

Transformer 编码器&解码器

Encoder&Decoder

在这个12288维空间中进行Encoding (Self Attention)

计算向量之间的相关度，根据相关度系数加权求和

我 向量a

a1

们 向量b

b1

是 向量c

c1

共 向量d

产 向量e

主 向量f

义 向量g

接 向量h

班 向量i

人 向量j

Transformer 编码器&解码器

Encoder&Decoder

在这个12288维空间中进行Encoding (Self Attention)

计算向量之间的相关度，根据相关度系数加权求和

我	向量a	a1
们	向量b	b1
是	向量c	c1
共	向量d	d1
产	向量e	e1
主	向量f	f1
义	向量g	g1
接	向量h	h1
班	向量i	i1
人	向量j	j1

Transformer 编码器&解码器

Encoder&Decoder

在这个12288维空间中进行Encoding (Self Attention)

计算向量之间的相关度，根据相关度系数加权求和

我	向量a	a1		a2
们	向量b	b1		
是	向量c	c1		
共	向量d	d1		
产	向量e	e1		
主	向量f	f1		
义	向量g	g1		
接	向量h	h1		
班	向量i	i1		
人	向量j	j1		

Transformer 编码器&解码器

Encoder&Decoder

在这个12288维空间中进行Encoding (Self Attention)

计算向量之间的相关度，根据相关度系数加权求和

我	向量a	a1		a2
们	向量b	b1		
是	向量c	c1		
共	向量d	d1		
产	向量e	e1		
主	向量f	f1		
义	向量g	g1		
接	向量h	h1		
班	向量i	i1		
人	向量j	j1		

Transformer 编码器&解码器

Encoder&Decoder

在这个12288维空间中进行Encoding (Self Attention)

计算向量之间的相关度，根据相关度系数加权求和

我	向量a	a1		a2
们	向量b	b1		
是	向量c	c1		
共	向量d	d1		
产	向量e	e1		
主	向量f	f1		
义	向量g	g1		
接	向量h	h1		
班	向量i	i1		
人	向量j	j1		

Transformer 编码器&解码器

Encoder&Decoder

在这个12288维空间中进行Encoding (Self Attention)

计算向量之间的相关度，根据相关度系数加权求和



Transformer 编码器&解码器

Encoder&Decoder

在这个12288维空间中进行Encoding (Self Attention)

计算向量之间的相关度，根据相关度系数加权求和

我	向量a	a1	a2
们	向量b	b1	
是	向量c	c1	
共	向量d	d1	
产	向量e	e1	
主	向量f	f1	
义	向量g	g1	
接	向量h	h1	
班	向量i	i1	
人	向量j	j1	

Transformer 编码器&解码器

Encoder&Decoder

在这个12288维空间中进行Encoding (Self Attention)

计算向量之间的相关度，根据相关度系数加权求和

我	向量a	a1	a2
们	向量b	b1	b2
是	向量c	c1	
共	向量d	d1	
产	向量e	e1	
主	向量f	f1	
义	向量g	g1	
接	向量h	h1	
班	向量i	i1	
人	向量j	j1	

Transformer 编码器&解码器

Encoder&Decoder

在这个12288维空间中进行Encoding (Self Attention)

计算向量之间的相关度，根据相关度系数加权求和

我	向量a	a1	a2
们	向量b	b1	b2
是	向量c	c1	c2
共	向量d	d1	
产	向量e	e1	
主	向量f	f1	
义	向量g	g1	
接	向量h	h1	
班	向量i	i1	
人	向量j	j1	

Transformer 编码器&解码器

Encoder&Decoder

在这个12288维空间中进行Encoding (Self Attention)

计算向量之间的相关度，根据相关度系数加权求和

我	向量a	a1	a2
们	向量b	b1	b2
是	向量c	c1	c2
共	向量d	d1	d2
产	向量e	e1	e2
主	向量f	f1	f2
义	向量g	g1	g2
接	向量h	h1	h2
班	向量i	i1	i2
人	向量j	j1	j2

Transformer 编码器&解码器

Encoder&Decoder

在这个12288维空间中进行Encoding (Self Attention)

计算向量之间的相关度，根据相关度系数加权求和

我	向量a	a1	a2	a9
们	向量b	b1	b2	b9
是	向量c	c1	c2	c9
共	向量d	d1	d2	d9
产	向量e	e1	e2	e9
主	向量f	f1	f2	f9
义	向量g	g1	g2	g9
接	向量h	h1	h2	h9
班	向量i	i1	i2	i9
人	向量j	j1	j2	j9

Transformer 编码器&解码器

Encoder&Decoder

在这个12288维空间中进行Encoding (Self Attention)

计算向量之间的相关度，根据相关度系数加权求和

我	向量a	a1	a2	a9	a96
们	向量b	b1	b2	b9	b96
是	向量c	c1	c2	c9	c96
共	向量d	d1	d2	d9	d96
产	向量e	e1	e2	e9	e96
主	向量f	f1	f2	f9	f96
义	向量g	g1	g2	g9	g96
接	向量h	h1	h2	h9	h96
班	向量i	i1	i2	i9	i96
人	向量j	j1	j2	j9	j96

Transformer 编码器&解码器

Encoder&Decoder

在这个12288维空间中进行Encoding (Self Attention)

计算向量之间的相关度，根据相关度系数加权求和

北京时间8月1	a1	a2	a9	a96
日凌晨，参加	b1	b2	b9	b96
男子100米自由	c1	c2	c9	c96
泳的潘展乐像	d1	d2	d9	d96
一道闪电，划	e1	e2	e9	e96
破了巴黎的夜	f1	f2	f9	f96
空——他以46	g1	g2	g9	g96
秒40打破世界	h1	h2	h9	h96
纪录的成绩赢	i1	i2	i9	i96
得冠军!	j1	j2	j9	j96

必须要掌握的几个概念

向量、空间、特征

向量，是高维数学空间中的点，是人类语言在新空间中的数学特征表述，这种向量高度抽象和提炼了人类语言的语意信息。

Arrangement

Single Agent (LLM Mode)

GPT-4o (8K)

User message billing (off)

Preview & Debug

Skills

Debug

Persona & Prompt

Optimize

Character

你是一个专业的金融投资研究助手，你非常严谨，你会按照以下步骤进行工作：

- ## 步骤
1. 你收到的金融相关用户请求都会唤起FrameSelection 工作流，你会完全把任务处理交给该工作流；

2. 将最终选择的分析框架名称，作为Rewrite 工作流的输入，并唤起Rewrite 工作流；

3. 输出“框架选择结果：”，输出最终选择的分析框架名称；

4. 输出“需求重写结果：”；

5. Rewrite 工作流结束之后，逐个输出Rewrite 工作流的返回结果，一个一个输出，每个一行，每行的开始位置先输出一个“.”；

6. 除此之外不输出任何其他内容。

Skills

Plugins

Plugins allow the bot to call external APIs that enable it to search for information, browse web pages, generate images, and more, expanding the bot's capabilities and applications.

Workflows

- FrameSelection_0809

金融投研助手，根据用户不同的请求，选择不同的分析框架进行服务
- Rewrite_0809

将用户的提问进行改写，改写多个适合检索的表述方式，让检索结果更...

Triggers

Knowledge

- Text
- Table
- Images

Memory

- Variables

广发银行基金最新市场观点及竞争力分析

27.9s | 8835 Tokens

user100702742714

小孩2岁了，是否可以开始学习骑自行车

金融投研助手_0809

对不起，我无法提供与金融投资研究无关的建议或信息。如果您有任何金融相关的问题，请随时告诉我！

2.1s | 1786 Tokens

孩子学习游泳的最佳年龄是多少？

如何教孩子安全使用剪刀？

小孩学习写字的时机是什么时候？







The content is generated by AI and is used for reference only, as it may be untrue and inaccurate.

Transformer 编码器&解码器

Encoder&Decoder


在这个12288维空间中进行Encoding (Self Attention)

计算向量之间的相关度，根据相关度系数加权求和

我是一个专	a1	a2	a9	a96
业的金融投	b1	b2	b9	b96
资研究助手。	c1	c2	c9	c96
现在用户的	d1	d2	d9	d96
问题是：“小	e1	e2	e9	e96
孩2岁了，	f1	f2	f9	f96
是否可以开	g1	g2	g9	g96
始学习骑自	h1	h2	h9	h96
行车	i1	i2	i9	i96
”	j1	j2	j9	j96

为什么要懂这些深度知识？

中国移动宽带
业务视频排障



主流模型能力对比

能力维度	GPT-5.4	Claude Opus 4.6	Gemini 3.1 Pro	豆包 Seed 2.0	通义千问 3.5	文心一言 5.0	DeepSeek V3.2
综合推理	★★★★★	★★★★★	★★★★	★★★★★	★★★★★	★★★★★	★★★★★
数学 / 逻辑	★★★★★	★★★★★	★★★★★	★★★★★	★★★★★	★★★★★	★★★★★
代码生成	★★★★★	★★★★★	★★★★★	★★★★★	★★★★★	★★★★	★★★★★
中文理解	★★★★	★★★★	★★★★	★★★★★	★★★★★	★★★★★	★★★★★
多模态（文 / 图 / 音 / 视频）	★★★★★	★★★★★	★★★★★	★★★★★	★★★★★	★★★★★	★★★★
长文本处理	1M Token	1M Token	10M Token	128K	200K	128K	128K
响应速度	中	慢	中	快	快	中	极快
价格（每百万 Token）	\$3/\$15	\$5/\$25	\$2/\$12	¥ 0.1/¥ 0.3	¥ 0.04/¥ 0.12	¥ 0.05/¥ 0.15	¥ 0.002/¥ 0.008

入职AI应用开发的必备应用技能

段位	年薪	Prompt	Agent	RAG	Fine tune	垂直行业LLM
最初级	5-15w	优秀				
初级	10-30w	优秀	优秀			
中级	30-80w	优秀	优秀	优秀	合格	
高级	100w起	优秀	优秀	优秀	优秀	
顶级	200w起	-	-	-	优秀	优秀

重点：深度理解原理+应用技术+项目实操经验

「大模型应用开发工程师岗位」能力模型

能力层级	核心技能项	具体知识点
一、基础与架构 (地基)	1. 主流模型架构原理	Transformer、SFT（监督微调）、RLHF（基于人类反馈的强化学习）基础
	2. 推理优化与部署	vLLM推理加速、模型量化、Docker/K8s容器化部署
	3. 向量数据库	Milvus/Pinecone/Chroma 的使用与索引优化（配合Embedding）
二、核心应用开发 (主干)	4. 提示词工程	零样本/少样本、思维链（CoT）、结构化输出
	5. RAG 应用开发	包含 Embedding 选型、重排序（Rerank）、多路召回策略
	6. Agent 智能体开发	包含 Function Calling / Tool Use、Planning（规划）、记忆（Memory）管理
三、进阶调优与闭环 (顶层)	7. 模型微调（Fine-tuning）	LoRA/QLoRA 微调、数据处理与格式化
	8. 工程化框架	LangGraph / LangChain（作为连接以上所有模块的编排层）
	9. 评估与数据飞轮	自动化评估指标（RAGAS）、Bad Case分析、数据回流策略

AI高薪岗位

AI应用高级工程师 20k-35k 前程无忧

惠州 / 经验5-10年 / 本科及以上 / 算法工程师 / 全职

☆ 收藏

投简

华阳通用

职位诱惑:

免费班车,五险一金,绩效奖金

职位描述:

职责描述:

1、将现有AI技术栈（LLM/Embedding模型+自动化流程）与公司研发、生产、管理等场景深度结合，设计智能化工具链，优化业务流程效率。

任职要求:

- 1、熟悉LangChain/LLamaIndex等AI应用框架。
- 2、掌握dify/Coze等低代码平台二次开发。
- 3、具备ollama、xinference等开源框架部署调优经验。
- 4、理解RAG技术原理及优化方法。
- 5、掌握Embedding模型微调与向量检索优化。
- 6、具备多模型协同调度经验（如路由模型+生成模型）。
- 7、熟练Python及FastAPI/Django框架。
- 8、掌握自动化脚本开发（Selenium/Airflow等）。
- 9、熟悉Linux服务器运维基础。
- 10、具备制造业/B端场景AI落地经验者优先（如智能客服、知识管理、流程挖掘、生产排程优化、设备预测性维护）。
- 11、主导过企业级知识库系统建设（含权限管理、版本控制等）。
- 12、熟悉汽车电子行业技术文档体系（如APQP/PPAP文档智能处理）。

大模型应用开发 26-50K

北京 1-3年 学历不限

职位描述

两年以上的工作经验。最好能够讲课。有辅导别人的经验。

岗位职责:

1. 负责大模型的应用开发与优化
2. 参与模型的构建、训练及技术支持
3. 与团队合作，确保模型的准确性和效率

任职要求:

1. 对大模型技术有深入理解
2. 具备良好的团队协作能力和问题解决能力
3. 能够高效地进行项目管理和执行

AI高薪岗位

大模型应用开发 35-60K·16薪

北京 3-5年 本科

☆ 收藏

立即沟通

职位描述

微信扫码分享 举报

- 1、建设AI原生智能研发产品，包括但不限于AI Coding IDE、研发 Agent、代码大模型等，利用技术手段提高研发人员的开发效率。
- 2、利用Agent、RAG、Multi-Modal 等 AI 技术，打造 AI 程序员，覆盖前端、后端、测试等各种研发工种。
- 3、打造智能化的需求分析、估价、分发、调度系统，让人类与 AI 程序员高效协同，低成本高效率的完成各类复杂任务。

岗位要求

- 1、具有敏锐的分析和发现问题本质的能力，识别并针对本质问题进行快速优化。
- 2、有大模型训练、Agent构建、大模型场景应用项目经验，有智能研发领域项目经验优先。
- 3、有 AI RAG /智能BI 项目优先



知乎知学堂

AI高薪岗位

大模型专项-Agent应用开发工程师 20-40K·15薪

☆ 收藏

立即沟通

📍 北京 📅 3-5年 🎓 本科

职位描述

🗨️ 微信扫码分享

🚩 举报

岗位职责：

作为核心成员深度参与智能体应用平台的产品研发工作。

开发智能体流程编排等核心功能，打通与内部多种系统的接入能力。

负责AI Agent技术架构的设计与实现，搭建稳定高效、低延迟的生产组织，支持高应用量平台级别的部署需求。

面向业务应用场景，提升智能体全链路的逻辑推理、任务规划等能力。

探索创新更易上手开发的agent构建方式，更稳定可靠的agent的运行方式，突破大模型能力应用上限。

任职要求：

1、3年以上工作经验，熟练掌握Python，熟悉相关语言特性及最佳实践，具备优秀的代码风格和工程化能力、出色的数据结构和基础算法功底。

2、有Agent平台/应用开发经验者优先，熟悉coze，dify，langflow等LLM应用框架的设计思路和使用，了解RAG、Agent、MCP等机制，使用过langchain等开源系统，有prompt工程业务优化经验者优先。

3、有Agent系统及平台的性能优化、架构优化系统经验者优先。

4、熟悉大模型开发中常用中间件 如向量检索milvus、PostgreSql、redis等



豆包大模型FDE-火山方舟Maas

70-100K·18薪

深圳·南山区·科技园 5-10年 本科



舒女士

字节跳动 · 招聘专员

今日回复1次

职位详情

Java Python

豆包大模型FDE (Frontend Developer Engineer) -火山方舟Maas

职位描述

- 1、面向行业头部客户，深入理解客户业务场景，识别并解决客户流程中的核心痛点，通过创新的AI解决方案将“看似不可能”的挑战转化为可落地的技术方案；
- 2、基于大模型应用思维，设计并实施复杂的Agent架构和Workflow工作流，完成从方案设计到代码实现的全流程，实现多AI智能体协同工作，弥合大模型技术Demo与实际业务价值创造之间的差距；
- 3、基于一线实践，收集并反馈产品使用中的问题与改进建议，推动产品持续优化。

职位要求

立即沟通

AI交付工程师 (FDE) 20-40K·14薪

北京 5-10年 本科

☆ 收藏

立即沟通

工作职责：

1. 负责纷享销客CRM AI 产品在客户侧的实施落地工作，保障核心 AI 场景的交付效果；
2. 负责将客户侧反馈的需求与功能，归纳整理，形成对 AI 产品有价值的输入，驱动产品的持续完善；

任职要求：【岗位涉及出差，不可以出差的不考虑】

1. 本科及以上学历，计算机等相关专业，「1 年以上 AI 项目落地经验」或者「2 年以上 CRM领域项目交付经验」；
2. AI 方面能力要求：
 1. 具备扎实的提示词工程基础，熟悉 Dify、Coze、LangGraph 等业界常用 AI 低代码平台能力与配置，有相关 AI 项目落地经验优先；
 2. 了解 RAG 技术原理，熟悉知识库落地调优方法，具备对召回命中率优化经验；
 3. 了解业界 Agent 常用框架，了解各种推理框架原理，具备 Agent 项目落地以及效果优化经验；
3. CRM 领域方面交付能力要求：
 1. 具备CRM领域项目需求分析，方案制定，以及高质量交付落地的经验，能够产出项目所需的交付物；
 2. 熟悉 CRM 营销服至少一个领域的业务形态，最近 2 年至少参与交付过 3 个以上的项目；
 4. 以上要求至少具备一个方面的岗位要求，都具备者优先录用；
 5. 对 AI 有极高的热情，具备很好的团队协作能力和学习能力，具备良好的客户沟通能力，具备一定项目管理能力；
- 6、核心职责是面向客户的AI 项目交付
- 7、岗位要求：以做过AI应用开发（熟练的AI应用搭建）或者做过CRM业务实施转型AI交付



知乎知学堂 AI高薪岗位

AI Agent 工程师-智能体系统与上下文工程 40-70K

北京 经验不限 本科

☆ 收藏

立即沟通

职位描述

工作地点:

北京市,上海市,深圳市,美国(可远程) 杭州市

工作职责:

1. 构建可运行的 Agent: 实现 intent 识别/任务分解/规划执行/工具调用/记忆与状态管理/失败
 2. 端到端负责闭环: 问题定义、数据与工具接入、原型实现、线上/线下验证、评估与复盘, 转向)
 3. 设计并实现 Agent Runtime: 会话与任务状态机、并发与队列、超时与重试、权限与审计
 4. 与多角色协作: 把需求变成可执行的 agent spec, 把模型能力变成稳定的系统能力
 5. 推动 agent 技术路线图与关键架构决策: 工具协议、记忆方案、评测口径、发布与灰度机
- 任职资格:

1. 本科及以上学历(计算机/软件工程/AI 相关优先), 3 年以上后端/平台/AI 工程经验, 或有成熟经验
2. 熟练掌握至少一门主力语言(Python / Go / Java 等), 具备大型项目工程经验
3. 扎实的软件工程能力: 架构设计、可靠性、可观测、性能与成本优化、可维护性
4. 有“从 0 到可验证”的完整交付经验: 能把探索做成可运行系统, 并用评测/数据输出结论
5. 良好的跨团队协作与表达能力: 能清晰描述权衡、边界与风险

微

AI Agent工程师 - 发布后端 35-65K·16薪

北京 1-3年 本科

☆ 收藏

立即沟通

职位描述

微信扫码分享

举报

Java

内容发布链路

Elasticsearch

发布后端

MySQL

分布式系统

Agent 架构

AI Agent

工作职责

- 1、负责内容发布侧 Agent 后端开发, 方向包括但不限于: 核心发布链路、智能创作工具、创作者服务等
- 2、基于对业务的深入理解, 进行系统选型与架构设计, 并借助 Vibe Coding 工具高效完成功能开发
- 3、参与团队 Agent、Skill 等 AI 工具建设, 持续拓展 AI 工具能力边界, 提升研发效能
- 4、与算法团队深度协作, 共同打磨 AI 能力, 共同解决AI落地到C端业务中各种问题

任职资格

- 1、扎实的计算机基础知识, 较强的学习能力和逻辑推理能力
- 2、熟悉主流的Agent设计思想与架构范式, 擅长使用Claude Code、Cursor等Vibe Coding工具, 有“养虾”经验者优先
- 3、熟练使用Java、掌握 MySQL、MongoDB、Redis、RocketMQ、Kafka、ElasticSearch等常用服务组件
- 4、精通分布式系统的设计开发, 对微服务拆分和服务治理(包括服务发现、配置管理、流量控制、日志监控、容错容灾等)有深入理解和实战经验
- 5、对前沿技术有浓厚的好奇心, 对行业发展持续跟进